## Curs 7: Optimizarea modelelor, preprocesare, pipelines

## Optimizarea modelelor

In cursul anterior s-a aratat cum se poate folosi k-fold cross validation pentru estimarea performantei unui model. Totodata, s-a aratat o maniera simpla de cautare a valorilor celor mai potrivite pentru hiperparametri - in cazul respectiv, valoarea adecvata a numarului de vecini pentru un model de KNN.

Vom continua aceasta idee pentru mai multi hiperparametri, apoi folosim facilitatile bibliotecii sklearn pentru automatizarea procesului.

K-fold cross validation asigura ca fiecare din cele k partitii ale setului de date initial este pe rand folosit ca subset de testare:

```
In [1]: from sklearn.model selection import KFold
     !pip install prettytable --upgrade
     from prettytable import PrettyTable
     Requirement already up-to-date: prettytable in c:\anaconda3\lib\site-packages
     (0.7.2)
In [2]: kf = KFold(n splits=3)
     splits = kf.split(range(30))
     t = PrettyTable(['Iter', 'Train', 'Test'])
     t.align = 'l'
     for i, data in enumerate(splits):
        t.add_row([i+1, data[0], data[1]])
     print(t)
     -----+
     | Iter | Train
                                                     | Test
     2 3 4 5 6 7 8 9]
     | 2 | [ 0 1 2 3 4 5 6 7 8 9 20 21 22 23 24 25 26 27 28 29] | [10
     11 12 13 14 15 16 17 18 19]
     | 3 | [ 0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19] | [20
     21 22 23 24 25 26 27 28 29]
```

Folosim k-fold cross validation pentru a face evaluarea de modele pentru diferite valori ale hiperparametrilor.

```
In [3]: import numpy as np
    import pandas as pd
    print ('numpy: ', np.__version__)
    print ('pandas: ', pd.__version__)

numpy: 1.18.1
    pandas: 1.0.3

In [4]: from sklearn.model_selection import cross_val_score, train_test_split
    from sklearn.neighbors import KNeighborsClassifier
    from sklearn.metrics import accuracy_score

    from sklearn.datasets import load_iris

    iris = load_iris()
    X = iris.data
    y = iris.target
```

Pentru k-nearest neighbors vom cauta valorile optime pentru:

- numarul de vecini,  $k \in \{1, ..., 31\}$
- putere corespunzatoare metricii Minkowski:

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_{i=1}^{n} \left| x_i - y_i \right|^p \right)^{1/p}$$

Best score: 0.9420112781954886

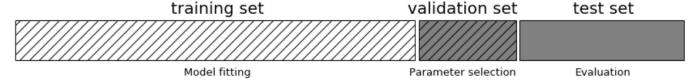
Best params: {'n\_neighbors': 6, 'p': 1}

Accuracy on whole set: 0.9525483304042179

Pentru procesul de mai sus urmatoarele comentarii sunt necesare:

- 1. strategia implementata se numeste grid search: se cauta peste toate combinatiile de 30\*4 variante si sa retine cea mai buna; este consumatoare de resurse, dar o prima varianta de lucru acceptabila
- am dori sa avem o modalitate automatizata de considerare a tuturor combinatiilor de parametri din multimea de valori candidat. Codul devine greu de scris cand sunt multi hiperparametri, fiecare cu multimea proprie de valori candidat
- 3. estimarea efectuata in final este de cele mai multe ori optimista: optimizarea parametrilor s-a facut peste niste date, care date in final sunt cele folosite pentru evaluarea finala; am ajuns practic sa facem evaluare pe setul de antrenare, ceea ce e o idee proasta. Estimarea finala a performantelor modelului trebuie facuta peste un set de date aparte, care nu a fost folosit nici pentru antrenare, nici pentru validarea modelelor candidat. Altfel, modelul poate face overfitting (invatare foarte buna a datelor de pe setul de antrenare, dar generalizare foarte slaba = rezultatul de pe un set de testare separat sutn foarte slabe).

Pentru ultimul punct se recomanda ca setul sa fie impartit ca mai jos:



Ca atare, va trebui sa rescriem codul astfel:

0.9

```
In [6]:
        X trainval, X test, y trainval, y test = train test split(X, y, test size=1/5)
        best score = 0
        for k in range(1, 31):
            for p in [1, 2, 3, 4.7]:
                model = KNeighborsClassifier(n neighbors=k, p=p)
                score = np.mean(cross_val_score(model, X_trainval, y_trainval, cv=10))
                if score >= best score:
                    best score = score
                    best_params = {'n_neighbors':k, 'p':p}
        print('Best score:', best_score)
        print('Best params:', best_params)
        model = KNeighborsClassifier(n_neighbors=best_params['n_neighbors'], p=best_pa
        rams['p'])
        model.fit(X trainval, y trainval)
        y_predicted = model.predict(X_test)
        print(accuracy_score(y_test, y_predicted))
        Best score: 0.983333333333333
        Best params: {'n_neighbors': 27, 'p': 3}
```

Desigur, si implementarea de mai sus e criticabila: s-a facut evaluare pe un singur set de testare, anume cel rezultat dupa impartirea initiala in partitiile \*\_trainvalid si \*\_test. Este totusi o estimare mai corect facuta decat cea precedenta. In realitate, acest stil de lucru este frecvent intalnit: exista un set de testare unic, dar necunoscut la inceput. Singurele date disponibile sunt impartite in *training set* si *validation set* (eventual mai multe) pentru a obtine un model care se spera ca generalizeaza bine = se comporta bine pe setul de testare.

Varianta anterioara se numeste **grid search with cross validation**. Exista clasa sklearn.model selection.GridSearchCV care automatizeaza procesul:

```
from sklearn.model selection import GridSearchCV
In [7]:
        X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=1/5)
        parameter_grid = {'n_neighbors': list(range(1, 10)), 'p': [1, 2, 3, 4.7]}
        grid_search = GridSearchCV(estimator = KNeighborsClassifier(), param_grid=para
        meter grid, scoring='accuracy', cv=5,
                                    return train score=True)
        grid_search.fit(X_train, y_train)
Out[7]: GridSearchCV(cv=5, error score=nan,
                     estimator=KNeighborsClassifier(algorithm='auto', leaf_size=30,
                                                     metric='minkowski',
                                                     metric_params=None, n_jobs=None,
                                                     n neighbors=5, p=2,
                                                     weights='uniform'),
                     iid='deprecated', n_jobs=None,
                     param grid={'n neighbors': [1, 2, 3, 4, 5, 6, 7, 8, 9],
                                  'p': [1, 2, 3, 4.7]},
                     pre_dispatch='2*n_jobs', refit=True, return_train_score=True,
                     scoring='accuracy', verbose=0)
In [8]: y_estimated = grid_search.predict(X_test)
        print(accuracy_score(y_test, y_estimated))
        0.9
```

Valorile optimale ale hiperparametrilor sunt retinute in atributul best\_params\_:

In codul anterior denumirile cheilor din dictionarul parameter\_grid nu sunt intamplatoare: ele coincid cu numele parametrilor modelului vizat. Instantierea estimator = KNeighborsClassifier() se face cu valorile implicite ale parametrilor, apoi insa se ruleaza metode de tip set\_ care seteaza parametrii dati in dictionarul parameter grid.

Pentru cei interesati, valorile de performanta pentru fiecare fold se pot inspecta. Pentru ca acestea sa fie disponibile, este obligatorie setarea parametrului return\_train\_score=True din clasa GridSearchCV.

```
df_grid_search = pd.DataFrame(grid_search.cv_results_)
In [10]:
         df_grid_search.info()
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 36 entries, 0 to 35
         Data columns (total 22 columns):
              Column
                                  Non-Null Count
                                                   Dtype
              ----
                                   -----
         ---
                                                   ----
              mean_fit_time
          0
                                  36 non-null
                                                   float64
              std_fit_time
          1
                                  36 non-null
                                                   float64
          2
              mean score time
                                  36 non-null
                                                   float64
          3
              std_score_time
                                  36 non-null
                                                   float64
          4
              param_n_neighbors
                                  36 non-null
                                                   object
          5
              param p
                                  36 non-null
                                                   object
                                  36 non-null
                                                   object
          6
              params
          7
              split0_test_score
                                  36 non-null
                                                   float64
          8
              split1 test score
                                  36 non-null
                                                   float64
          9
              split2_test_score
                                  36 non-null
                                                   float64
          10
              split3_test_score
                                  36 non-null
                                                   float64
              split4 test score
          11
                                  36 non-null
                                                   float64
          12
              mean test score
                                  36 non-null
                                                   float64
          13
              std_test_score
                                  36 non-null
                                                   float64
          14
              rank test score
                                  36 non-null
                                                   int32
          15
              split0_train_score
                                  36 non-null
                                                   float64
          16
              split1_train_score
                                  36 non-null
                                                   float64
          17
              split2 train score
                                  36 non-null
                                                   float64
              split3 train score
                                  36 non-null
                                                   float64
          18
          19
              split4_train_score
                                  36 non-null
                                                   float64
              mean train score
          20
                                  36 non-null
                                                   float64
              std train score
                                  36 non-null
                                                   float64
```

dtypes: float64(18), int32(1), object(3)

memory usage: 6.2+ KB

```
In [11]:
           df grid search.head()
Out[11]:
               mean_fit_time std_fit_time mean_score_time std_score_time param_n_neighbors
            0
                                                                                            1
                    0.000807
                                0.000404
                                                  0.002391
                                                                  0.001192
                                                                                                      2
            1
                    0.000603
                                0.000493
                                                  0.000998
                                                                  0.000001
                                                                                            1
                                                                                                      3
            2
                    0.000200
                                0.000400
                                                  0.001590
                                                                  0.000789
                                                                                            1
                                                                                                     4.7
            3
                    0.000601
                                0.000491
                                                  0.001794
                                                                  0.000746
                                                                                             1
                                                                                                      1
                    0.000399
                                0.000488
                                                  0.001406
                                                                  0.000491
           5 rows × 22 columns
```

Pentru situatia in care se doreste evaluarea nu doar pe un singur set de testare, ci in stil cross-validation, se poate face un *nested cross-validation*:

## Metode de preprocesare

Uneori, inainte de aplicarea vreunui model, este nevoie ca datele de intrare sa fie supuse unor transformari. De exemplu, daca pentru algoritmul k-NN vreuna din trasaturi (fie ea F) are valori de ordinul sutelor si celelalte de ordinul unitatilor, atunci distanta dintre doi vectori ar fi dominata de diferenta pe dimensiunea F; celelalte dimensiuni nu ar conta prea mult.

Intr-o astfel de situatie se recomanda sa se faca o scalare in prealabil a datelor la intervale comparbile, de ex [0, 1].

In modulul sklearn.preprocessing se afla clasa MinMaxScaler care permite scalarea independenta a trasaturilor. Il vom demonstra pe un set de date care are trasaturi cu marimi disproportionate.

```
In [14]: from sklearn.datasets import load_breast_cancer
medical = load_breast_cancer()
X, y = medical.data, medical.target
```

```
In [15]: def print_ranges(X):
    for col_index in range(X.shape[1]):
        column = X[:, col_index]
        print(np.min(column), np.max(column))

print_ranges(X)

6.981 28.11
9.71 39.28
43.79 188.5
143.5 2501.0
0.05263 0.1634
0.01938 0.3454
0.0 0.4268
0.0 0.2012
0.106 0.304
```

0.04996 0.09744 0.1115 2.873 0.3602 4.885 0.757 21.98 6.802 542.2 0.001713 0.03113 0.002252 0.1354

0.0 0.3960.0 0.052790.007882 0.078950.0008948 0.02984

7.93 36.04 12.02 49.54 50.41 251.2 185.2 4254.0 0.07117 0.2226 0.02729 1.058 0.0 1.252 0.0 0.291 0.1565 0.6638 0.05504 0.2075

```
In [16]: from sklearn.preprocessing import MinMaxScaler
      scaler = MinMaxScaler()
      scaler.fit(X)
      X = scaler.transform(X)
      print_ranges(X)
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 0.9999999999999999
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 1.000000000000000002
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 0.99999999999998
      0.0 1.0
      0.0 1.0
      0.0 1.0
      0.0 1.0
```

De mentionat ca secventa fit si transform se poate apela intr-un singur pas:

```
In [17]: | X, y = medical.data, medical.target
     X = scaler.fit transform(X)
     print_ranges(X)
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.00000000000000002
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 0.99999999999998
     0.0 1.0
     0.0 1.0
     0.0 1.0
     0.0 1.0
```

De regula, setul de date se imparte in doua (in modul naiv): set de antrenare si set de testare. Se presupune ca setul de testare este cunoscut mult mai tarziu decat cel de antrenare. Ca atare, doar cel de antrenare se trece prin preprocesor, iar valorile 'invatate' via fit se pastreaza (obiectul de tip MinMaxScaler are stare). Ele vor fi folosite pentru scalarea setului de test:

```
In [18]: X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=1/3)
         scaler = MinMaxScaler()
         X train = scaler.fit transform(X train)
         X test = scaler.transform(X test)
         print ranges(X test)
         -0.036700848829792444 0.9661449389136945
         -0.028595817328211624 1.2334613743064444
         -0.0293782899416703 0.9886185801678762
         -0.015214205671924845 1.000861994655633
         0.11853389907014528 0.8311817279046674
         0.039077357217348646 0.8199496963376482
         0.0 1.0009380863039399
         0.0 1.0713525026624067
         0.07828282828282829 0.805555555555556
         0.006333260537235521 1.0369076217514739
         -0.0028689715281812918 0.8816095293434049
         -0.00042008445908598704 0.6097636472174932
         -0.00411144913205369 0.8424496477590474
         -0.0008720044140400431 1.0320249408696125
         0.03243022741951933 0.7348471971988986
         0.005707934028299334 0.782197254183315
         0.0 0.7671717171717172
         0.0 0.6605417692744838
         0.02331569764169529 0.7281476895367818
         0.0019139615549382955 0.7588546632947778
         -0.04228732207878186 1.1208209202250912
         -0.06643244969658257 1.131906739061003
         -0.03801401157477917 1.1851964666463597
         -0.018448200544373128 1.3488020430794045
         0.10942349600475473 0.9154724955424949
         0.021577359296019248 0.8140117006723521
         0.0 1.07008547008547
         0.0 0.9470790378006874
         0.05179377524352575 1.2052744119743404
         0.02813852813852813 0.773711137347501
```

Se remarca faptul ca, folosindu-se parametrii de scalare din setul de antrenare, nu se poate garanta ca setul de testare este cuprins de asemenea in hipercubul unitate  $[0, 1]^{X.shape[1]}$ 

Exista si alte metode de preprocesare in modulul <u>sklearn.preprocessing (http://scikitlearn.org/stable/modules/preprocessing.html)</u>.

## **Pipelines**

Se prefera inlantuirea intr-un proces a pasilor: preprocesare si aplicare de model. Exemplificam pentru cazul simplu in care exista un set de antrenare si unul de testare:

```
In [19]: X, y = medical.data, medical.target
    X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=1/3)

In [20]: from sklearn.pipeline import Pipeline
    pipe = Pipeline([('scaler', MinMaxScaler()), ('knn', KNeighborsClassifier())])
    pipe.fit(X_train, y_train)
    y_predicted = pipe.predict(X_test)
    print(accuracy_score(y_test, y_predicted))

0.9789473684210527
```

Pentru cazul in care se vrea k-fold cross validation pentru determinarea valorilor optime pentru hiperparametri, urmata de testare pe un set de testare:

```
In [21]: X_trainval, X_test, y_trainval, y_test = train_test_split(X, y, test_size=1/3)
         parameter grid = {'knn n neighbors': list(range(1, 10)), 'knn p': [1, 2, 3,
         grid = GridSearchCV(pipe, param_grid = parameter_grid, scoring = 'accuracy', c
         grid.fit(X_trainval, y_trainval)
Out[21]: GridSearchCV(cv=5, error score=nan,
                      estimator=Pipeline(memory=None,
                                          steps=[('scaler',
                                                  MinMaxScaler(copy=True,
                                                               feature_range=(0, 1))),
                                                 ('knn',
                                                  KNeighborsClassifier(algorithm='aut
         ο',
                                                                       leaf size=30,
                                                                       metric='minkowsk
         i',
                                                                       metric params=No
         ne,
                                                                       n_jobs=None,
                                                                       n neighbors=5, p
         =2,
                                                                       weights='unifor
         m'))],
                                          verbose=False),
                      iid='deprecated', n_jobs=None,
                      param grid={'knn n neighbors': [1, 2, 3, 4, 5, 6, 7, 8, 9],
                                   'knn_p': [1, 2, 3, 4.7]},
                      pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
                      scoring='accuracy', verbose=0)
In [22]: y predicted = grid.predict(X test)
         print(accuracy score(y test, y predicted))
```