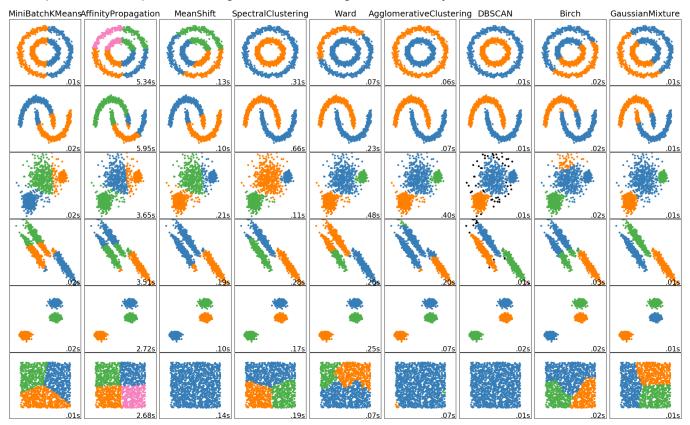
# Invatare nesupervizata si preprocesare (2)

## Clustering

Scop: partitionarea datelor in grupuri. Ideal, clusterele ar trebui sa aiba urmatoarele proprietati: punctele dintr-un cluster oarecare ar trebui sa fie similare, punctele din clustere diferite sa fie foarte diferite. Pentru un punct nou dat trebuie determinat clusterul de care apartine. In functie de varianta de algoritm de clustering, se poate ca un punct nou sa fie de asemenea considerat "outlier" (nu se potriveste cu niciun cluster) sau poate avea diverse grade de apartenenta la clusterele rezultate - de ex. in fuzzy c-means.

Exista multiple variante de clustering, fiecare mergand pe strategie specifica. Rezultatele pentru un acelasi set de date peste care se aplica diferiti algoritmi de clustering sunt date mai jos:



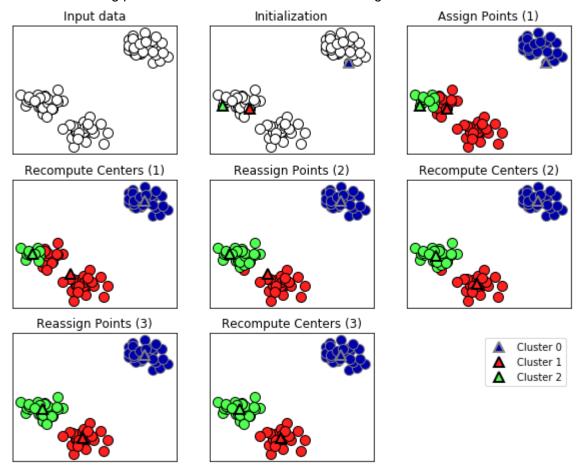
## k-means clustering

### Algoritmul este dat in Cursul de IA

(https://github.com/lmsasu/cursuri/blob/master/InteligentaArtificiala/curs/InteligentaArtificiala.pdf), sectiunea 8.4. k-means propune centri de cluster care sa minimizeze valoarea functiei:

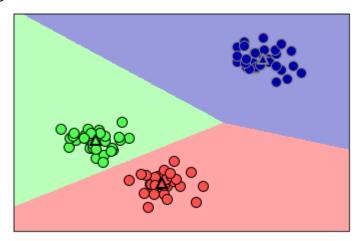
$$\sum_{i=1}^n \min_{\hat{\mu}_j \in C} \|x_i - \hat{\mu}_j\|^2$$

Evolutia pasilor de clustering pentru un set de date este aratata in imaginea urmatoare:



Sursa: Introduction to machine learning with Python

Fiecare cluster astfel realizat are asignata o intreaga zona de influenta: orice punct din spatiu apartine de clusterul in zona caruia se gaseste:



Sursa: Introduction to machine learning with Python

Zonele de influenta sunt configurate in functie de metrica folosita. Cea mai populara metrica este cea Euclidiana, un caz particular al <u>divergentei Bregman (http://www.jmlr.org/papers/volume6/banerjee05b/banerjee05b.pdf)</u>.

Utilizare de implementare sklearn:

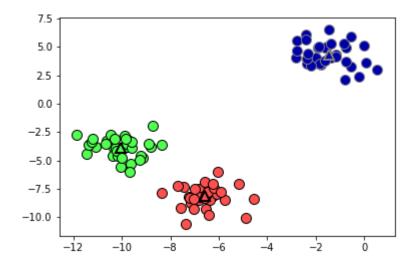
```
In [2]: %matplotlib inline
                                     from preamble import *
                                     plt.rcParams['image.cmap'] = "gray"
                                     from sklearn.datasets import make blobs
                                     from sklearn.cluster import KMeans
                                     # generate synthetic two-dimensional data
                                     X, y = make blobs(random state=1)
                                     # build the clustering model
                                     kmeans = KMeans(n clusters=3)
                                     kmeans.fit(X)
Out[2]: KMeans(algorithm='auto', copy x=True, init='k-means++', max iter=300,
                                                                  n clusters=3, n init=10, n jobs=None, precompute distances='auto',
                                                                  random state=None, tol=0.0001, verbose=0)
In [3]: | # plt.scatter(X[:, 0], X[:, 1], c=y)
In [4]: print("Cluster memberships:\n{}".format(kmeans.labels ))
                                    Cluster memberships:
                                     [0\; 2\; 2\; 2\; 1\; 1\; 1\; 2\; 0\; 0\; 2\; 2\; 1\; 0\; 1\; 1\; 1\; 0\; 2\; 2\; 1\; 2\; 1\; 0\; 2\; 1\; 1\; 0\; 0\; 1\; 0\; 0\; 1\; 0\; 2\; 1\; 2\; 1\; 0\; 1\; 0\; 1\; 0\; 0\; 1\; 0\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 1\; 0\; 
                                        \begin{smallmatrix} 2 & 2 & 1 & 1 & 2 & 0 & 2 & 2 & 1 & 0 & 0 & 0 & 0 & 2 & 1 & 1 & 1 & 0 & 1 & 2 & 2 & 0 & 0 & 2 & 1 & 1 & 2 & 2 & 1 & 0 & 1 & 0 & 2 & 2 & 2 & 1 & 0 \\ \end{smallmatrix}
```

Cei 3 centroizi sunt determinati cu:

Pentru un set de date, putem cere determinarea indicilor de cluster de care apartine fiecare punct din set prin metoda predict :

Apartenenta se decide, in mod firesc, gasind cel mai apropiat centroid de cluster.

Etichetele 0-2 sunt arbitrare, o rerulare a algoritmului poate duce la ordine diferita a etichetelor in vectorii de mai sus. Reprezentarea datelor impreuna cu centrii clusterelor (triunghiuri) este data mai jos:



Numarul de clustere k este dictat de catre utilizator. Algoritmul functioneaza cu un spectru larg de valori k:

```
In [8]: | fig, axes = plt.subplots(1, 2, figsize=(10, 5))
         # using two cluster centers:
         kmeans = KMeans(n clusters=2)
         kmeans.fit(X)
         assignments = kmeans.labels_
         mglearn.discrete_scatter(X[:, 0], X[:, 1], assignments, ax=axes[0])
         # using five cluster centers:
         kmeans = KMeans(n_clusters=5)
         kmeans.fit(X)
         assignments = kmeans.labels_
         mglearn.discrete\_scatter(X[:, 0], X[:, 1], assignments, ax=axes[1])
Out[8]: [<matplotlib.lines.Line2D at 0x21a21df9708>,
          <matplotlib.lines.Line2D at 0x21a21def6c8>,
          <matplotlib.lines.Line2D at 0x21a21df9e88>,
          <matplotlib.lines.Line2D at 0x21a21dfee08>,
          <matplotlib.lines.Line2D at 0x21a21dfeec8>]
            7.5
                                                     7.5
            5.0
                                                     5.0
            2.5
                                                     2.5
            0.0
                                                     0.0
           -2.5
                                                    -2.5
           -5.0
                                                    -5.0
          -7.5
                                                    -7.5
          -10.0
                                                   -10.0
```

Elementele de critica pentru algoritmul k-means sunt::

-io

-i2

- 1. alegerea incorecta a numarului k de centroizi nu se semnalata de catre algorim in niciun fel
- 2. clusterele sunt forme convexe (globulare), ceea ce nu se potriveste bine cu cazurile in care grupurile de date sunt elongate sau neconvexe

-i2

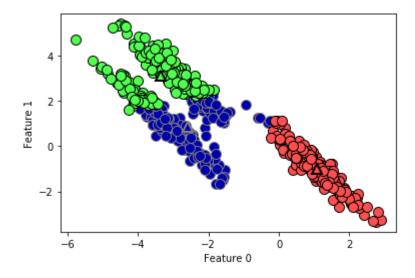
-i0

- 3. clusterele tind sa aiba acelasi diametru
- 4. pot rezulta clustere fara reprezentanti, daca centroizii se indeparteaza prea mult (rar, dar posibil)
- 5. suprafetele de separare sunt la mijlocul distantei dintre centroizi.

Pentru punctul 2 de mai sus avem exemplificare:

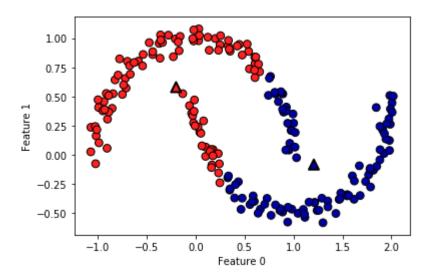
```
In [9]: # generate some random cluster data
        X, y = make_blobs(random_state=170, n_samples=600)
        rng = np.random.RandomState(74)
        # transform the data to be stretched
        transformation = rng.normal(size=(2, 2))
        X = np.dot(X, transformation)
        # cluster the data into three clusters
        kmeans = KMeans(n_clusters=3)
        kmeans.fit(X)
        y_pred = kmeans.predict(X)
        # plot the cluster assignments and cluster centers
        mglearn.discrete_scatter(X[:, 0], X[:, 1], kmeans.labels_, markers='o')
        mglearn.discrete_scatter(
            kmeans.cluster_centers_[:, 0], kmeans.cluster_centers_[:, 1], [0, 1, 2],
            markers='^', markeredgewidth=2)
        plt.xlabel("Feature 0")
        plt.ylabel("Feature 1")
```

### Out[9]: Text(0, 0.5, 'Feature 1')



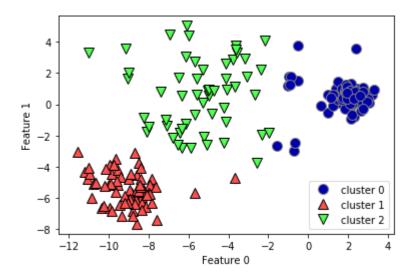
Pentru suprafete mai complicate, tendintele k-means sunt si mai clare. lata comportamentul pentru 2 forme de semiluna:

### Out[10]: Text(0, 0.5, 'Feature 1')



Legat de suprafetele de separare, avem demo-ul de mai jos:

Out[11]: Text(0, 0.5, 'Feature 1')



Pentru clusterele 0 si 1, datele aflate mai spre centrul figurii ar fi fost mai degraba vazute ca parte din clutserul 2. Mediatoarele segmentelor determinate de cei 3 centroizi dicteaza insa la cine se determina apartenenta.

Distanta (metrica) folosita are de asemenea impact asupra rezultatului clustering-ului. Daca se foloseste distanta Minkowski:

$$d(\mathbf{a},\mathbf{b}) = \left(\sum_{i=1}^d |a_i - b_i|^p
ight)^{rac{1}{p}}$$

atunci in mod necesar trasaturile trebuie sa fie pe aceeasi scala. In acest caz, distanta arata ca fiecare trasatura are aceasi importanta in calculul distantei. O abordare diferita este folosirea de metrici care sa fie invatate, pe baza unui semnal critic; domeniul se numeste **metric learning** si este o arie de cercetare activa:

- A Tutorial on Distance Metric Learning: Mathematical Foundations, Algorithms and Software (https://arxiv.org/abs/1812.05944)
- <u>Distance metric learning</u>, <u>with application to clustering with side-information</u> (<a href="https://ai.stanford.edu/~ang/papers/nips02-metric.pdf">https://ai.stanford.edu/~ang/papers/nips02-metric.pdf</a>)
- A Survey on Metric Learning for Feature Vectors and Structured Dat (https://arxiv.org/abs/1306.6709)

Alte comentarii pentru k-means:

- 1. algoritmul este rapid in practica, dar nu garanteaza determinarea centroizilor optimali;
- 2. se poate face rularea repetata a algoritmului k-means cu diverse intiializari ale centroizilor si apoi alegerea variantei care minimizeaza functia fata la inceputul notebook-ului:

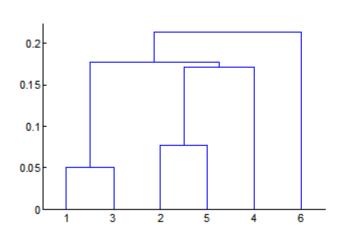
$$\sum_{i=1}^n \min_{\hat{\mu}_j \in C} \|x_i - \hat{\mu}_j\|^2$$

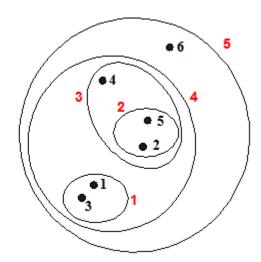
aceasta fiind varianta folosita in sklearn

- 3. alternativ, se poate folosi algoritmul k-means++ pentru initializarea centroizilor: <u>k-means++: The Advantages</u> of Careful Seeding (http://ilpubs.stanford.edu:8090/778/1/2006-13.pdf)
- 4. alternativ, se poate folosi algoritm care estimeaza numarul de clustere: X-means: Extending K-means with Efficient Estimation of the Number of Clusters (https://www.cs.cmu.edu/~dpelleg/download/xmeans.pdf)
- 5. alternativ: se poate folosi metoda siluetelor (https://en.wikipedia.org/wiki/Silhouette\_(clustering))

### Clustering ierarhic aglomerativ

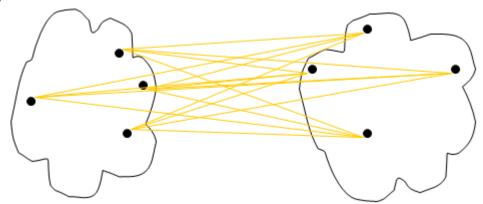
Clusteringul aglomerativ pleaca de la ideea ca initial fiecare punct din setul de date este un cluster; succesiv, clusterele apropiate se unsesc si formeaza clustere mai mari; daca aglomerarea de clustere continua, atunci se poate ajunge la un singur cluster care contine toate datele; de regula, procesul este oprit atunci cand se ajunge la un anumit numar de clustere.





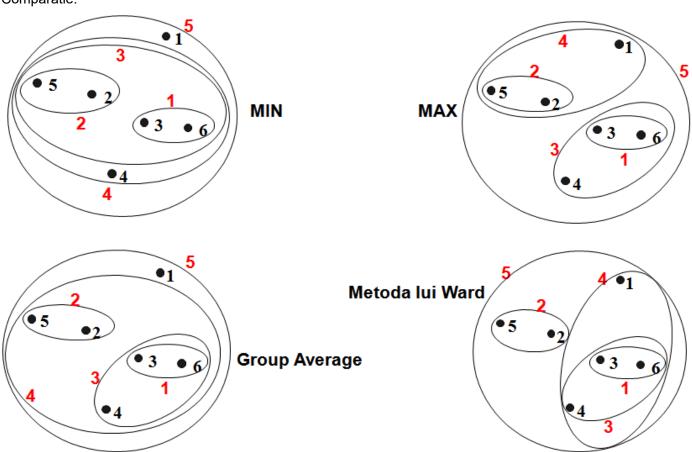
Modalitatile de masurare a similaritatii clusterelor se bazeaza pe un criteriu de legatura - linkage. Variante:

- Metoda lui Ward se face alegerea clusterelor care se vor uni de asa maniera incat cresterea variantei in interiorul clusterelor sa fie minima
- average se unesc cele 2 clustere care minimizeaza distanta medie intre perechile de puncte ce apartin de aceste clustere

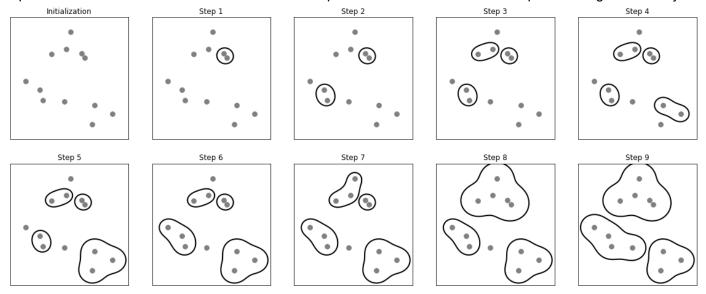


• complete - uneste acele clustere pentru care distanta maxima dintre perechi de puncte este de valoare minima

### Comparatie:



In practica metoda lui Ward da rezultate bune. Pasii pentru un set de date sunt exemplificati in figura de mai jos:



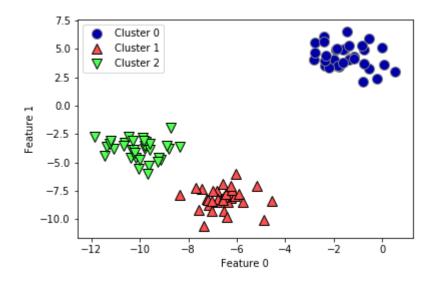
### Exemplu de utilizare in sklearn:

```
In [12]: from sklearn.cluster import AgglomerativeClustering
X, y = make_blobs(random_state=1)

agg = AgglomerativeClustering(n_clusters=3)
assignment = agg.fit_predict(X)

mglearn.discrete_scatter(X[:, 0], X[:, 1], assignment)
plt.legend(["Cluster 0", "Cluster 1", "Cluster 2"], loc="best")
plt.xlabel("Feature 0")
plt.ylabel("Feature 1")
```

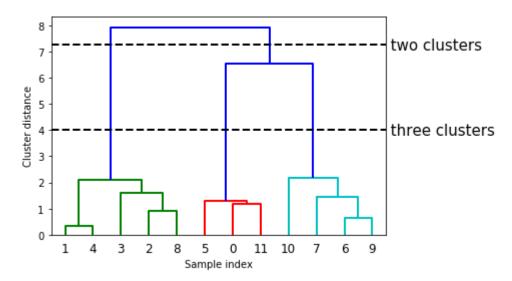
Out[12]: Text(0, 0.5, 'Feature 1')



Exista o posibilitate de a cum decurge procesul de clustering aglomerativ, folosind un arbore (o dendrograma) ce arata in ce ordine se fac unirile de clustere. Metoda are avantajul ca se poate aplica pentru date in oricate dimensiuni; importanta este doar referirea la datele initiale, pentru a arata in ce ordine se face aglomerarea lor.

```
In [13]:
         # Import the dendrogram function and the ward clustering function from SciPy
         from scipy.cluster.hierarchy import dendrogram, ward
         X, y = make_blobs(random_state=0, n_samples=12)
         # Apply the ward clustering to the data array X
         # The SciPy ward function returns an array that specifies the distances
         # bridged when performing agglomerative clustering
         linkage array = ward(X)
         # Now we plot the dendrogram for the linkage array containing the distances
         # between clusters
         dendrogram(linkage array)
         # mark the cuts in the tree that signify two or three clusters
         ax = plt.gca()
         bounds = ax.get xbound()
         ax.plot(bounds, [7.25, 7.25], '--', c='k')
         ax.plot(bounds, [4, 4], '--', c='k')
         ax.text(bounds[1], 7.25, ' two clusters', va='center', fontdict={'size': 15})
         ax.text(bounds[1], 4, ' three clusters', va='center', fontdict={'size': 15})
         plt.xlabel("Sample index")
         plt.ylabel("Cluster distance")
```

Out[13]: Text(0, 0.5, 'Cluster distance')



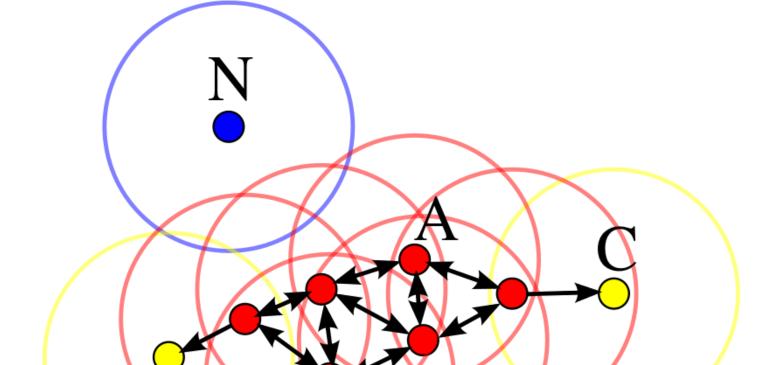
### **DBSCAN**

Algoritmul DBSCAN (density based spatial clustering of applications with noise) este creatia lui Hans-Peter Kriegel si a altor colaboratori. Algoritmul a trecut "testul timpului", iar autorul principal a fost recompensat cu 2014 SIGKDD TEST OF TIME AWARD (https://www.kdd.org/News/view/2014-sigkdd-test-of-time-award).

Punctele din setul de date sunt vazute astfel (sursa: Wikipedia)

Exemplu:

- A point p is a core point if at least minPts points are within distance ε of it (including p).
- A point q is directly reachable from p if point q is within distance ε from core point p. Points are only said to be directly reachable from core points.
- A point q is reachable from p if there is a path p1, ..., pn with p1 = p and pn = q, where each pi+1 is directly reachable from pi. Note that this implies that all points on the path must be core points, with the possible exception of q.
- All points not reachable from any other point are outliers or noise points.



In imaginea de mai sus: minPts = 4, punctele rosii sunt core points, B si C nu sunt core points dar pot fi ajunse din A; punctele galbene si rosii apartin de acelasi cluster. Punctul N este zgomot - nu face parte din cluster.

### Algoritm:

```
DBSCAN(DB, distFunc, eps, minPts) {
   C = 0
                                                           /* Cluster counter */
   for each point P in database DB {
      if label(P) # undefined then continue
                                                           /* Previously processed in inner loop */
      Neighbors N = RangeQuery(DB, distFunc, P, eps)
                                                           /* Find neighbors */
                                                           /* Density check */
      if |N| < minPts then {</pre>
                                                           /* Label as Noise */
         label(P) = Noise
         continue
      C = C + 1
                                                           /* next cluster label */
                                                           /* Label initial point */
      label(P) = C
                                                           /* Neighbors to expand */
      Seed set S = N \setminus \{P\}
      for each point Q in S {
                                                           /* Process every seed point */
         if label(Q) = Noise then label(Q) = C
                                                           /* Change Noise to border point */
         if label(Q) # undefined then continue
                                                           /* Previously processed */
         label(Q) = C
                                                           /* Label neighbor */
         Neighbors N = RangeQuery(DB, distFunc, Q, eps) /* Find neighbors */
                                                           /* Density check */
         if |N| \ge minPts then {
             S = S \cup N
                                                           /* Add new neighbors to seed set */
   }
```

Parametrii eps si minPts determina comportamentul algoritmului.

Desi mai lent decat k-means, nu necesita precizarea unui numar de clustere. In plus, suprafetele de separare pot fi neliniare, iar clusterele pot fi ne-globulare si de dimensiuni diferite:

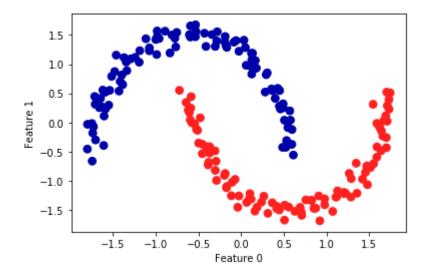
```
In [15]: from sklearn.preprocessing import StandardScaler
    from sklearn.cluster import DBSCAN

X, y = make_moons(n_samples=200, noise=0.05, random_state=0)

# Rescale the data to zero mean and unit variance
scaler = StandardScaler()
scaler.fit(X)
X_scaled = scaler.transform(X)

dbscan = DBSCAN()
clusters = dbscan.fit_predict(X_scaled)
# plot the cluster assignments
plt.scatter(X_scaled[:, 0], X_scaled[:, 1], c=clusters, cmap=mglearn.cm2, s=60
)
plt.xlabel("Feature 0")
plt.ylabel("Feature 1")
```

### Out[15]: Text(0, 0.5, 'Feature 1')



Despre efectul parametrilor minPts si eps:

- 1. daca eps se seteaza la valoare prea mica, atunci niciun punct nu va fi core point si toate datele vor fi etichetate ca zgomot
- 2. daca eps se seteaza la o valoare prea mare, se va forma un singur cluster
- 3. daca minPts se seteaza la o valoare prea mare, exista riscul ca multe puncte sa fie declarate ca zgomot

```
In [ ]:
```